


## 4 Multivariate Differentiation

### 4.2 zweiter Ordnung 4.3 diskrete Ableitungen

Mathe II  
HTWG - Fakultät für Informatik  
Prof. Dr. R. Axthelm


## Multivariate Differentiation

Ableitungsterme zweiter Ordnung  
von diskreten, multivariaten Funktionen



Ludwig-Otto Hesse  
1811-1874


$$J\nabla f = \text{grad } \nabla f$$



Ludwig-Otto Hesse  
1811-1874


$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix}$$

$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \text{grad } f_x \\ \text{grad } f_y \end{pmatrix}$$




Ludwig-Otto Hesse  
1811-1874

$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \text{grad}f_x \\ \text{grad}f_y \end{pmatrix} = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$$



Ludwig-Otto Hesse  
1811-1874



Ludwig-Otto Hesse  
1811-1874

$$J\nabla f = \text{grad } \nabla f = \text{grad} \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} \text{grad} f_x \\ \text{grad} f_y \end{pmatrix} = \begin{pmatrix} f_{xx} & f_{xy} \\ f_{yx} & f_{yy} \end{pmatrix}$$

### Definition: Hesse-Matrix

Sei  $f \in C^2(D \subseteq \mathbb{R}^n)$ , also auf  $D$  zwei mal partiell differenzierbar. Dann heißt die Matrix

$$Hf = \begin{pmatrix} f_{x_1 x_1} & \cdots & f_{x_1 x_n} \\ \vdots & & \vdots \\ f_{x_n x_1} & \cdots & f_{x_n x_n} \end{pmatrix}$$

Hesse-Matrix der Funktion  $f$ .

Dabei meint

$$f_{x_i x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} = \frac{\partial}{\partial x_j} \frac{\partial}{\partial x_i} f$$

erste partielle Ableitung in Richtung  $x_i$  und zweite partielle Ableitung in Richtung  $x_j$ .

Beispiel: Hesse-Matrix

Beispiel:

Für  $f(x) = 2x_1^2 x_2 + x_2^3$

$$f_{x_1} = 4x_1 x_2, \quad f_{x_2} = 2x_1^2 + 3x_2^2,$$

$$f_{x_1 x_1} = 4x_2, \quad f_{x_1 x_2} = 4x_1,$$

$$f_{x_2 x_1} = 4x_1, \quad f_{x_2 x_2} = 6x_2.$$

Die Hesse-Matrix lautet dann

$$Hf = \begin{pmatrix} 4x_2 & 4x_1 \\ 4x_1 & 6x_2 \end{pmatrix}.$$

Beispiel: Hesse-Matrix

Beispiel:

Für  $f(x) = 2x_1^2 x_2 + x_2^3$

$$\begin{array}{ll} f_{x_1} = 4x_1 x_2, & f_{x_2} = 2x_1^2 + 3x_2^2, \\ f_{x_1 x_1} = 4x_2, & f_{x_1 x_2} = 4x_1, \\ f_{x_2 x_1} = 4x_1, & f_{x_2 x_2} = 6x_2. \end{array}$$

Die Hesse-Matrix lautet dann

$$Hf = \begin{pmatrix} 4x_2 & 4x_1 \\ 4x_1 & 6x_2 \end{pmatrix}.$$

### Definition & Satz: Extrema

Stellen  $x \in \mathbb{D}_u$  heißen kritische Punkte von  $u$ , wenn

$$\|\nabla u(x)\| = 0$$

gilt.

$u$  hat bei  $x$  ein lokales Minimum, wenn  $Hu(x)$  positiv definit ist, d.h., dass die Matrix nur positive Eigenwerte besitzt.

$u$  hat bei  $x$  ein lokales Maximum, wenn  $Hu(x)$  negativ definit ist, d.h., dass die Matrix nur negative Eigenwerte besitzt.


Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$\lambda = 2 \Rightarrow$  positiv definit




Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$


$\lambda = 2 \Rightarrow$  positiv definit



$$u(x) = -x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$$

$\lambda = -2 \Rightarrow$  negativ definit




Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$


$\lambda = 2 \Rightarrow$  positiv definit



$$u(x) = -x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$$


$\lambda = -2 \Rightarrow$  negativ definit



$$u(x) = x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

$\lambda \in \{-2, 2\} \Rightarrow$  indefinit



## 4. Multivariate Differentiation

## Ableitungsterme zweiter Ordnung


Maximum oder Minimum

$$u(x) = x_1^2 + x_2^2$$

$$P_K = (0, 0)$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$


$\lambda = 2 \Rightarrow$  positiv definit



$$u(x) = -x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} -2 & 0 \\ 0 & -2 \end{pmatrix}$$


$\lambda = -2 \Rightarrow$  negativ definit



$$u(x) = x_1^2 - x_2^2$$

$$Hu(P_k) = \begin{pmatrix} 2 & 0 \\ 0 & -2 \end{pmatrix}$$

$\lambda \in \{-2, 2\} \Rightarrow$  indefinit




$$u(x) = 2x_1^2(1-x_2) + (x_2+1)^3$$


$$P_k = (-1, 0)$$

$$Hu(P_k) = \begin{pmatrix} 8 & 0 \\ 0 & 0 \end{pmatrix}$$



$\lambda \in \{8, 0\} \Rightarrow$  pos. semi definit




Baywatch: Optimierungsproblem




Memo: Schnellster Weg zur Ertrinkenden:



Baywatch: Optimierungsproblem



allgemein:



benötigte Zeit  $T(y)$  und partielle Ableitungen  $T_{,y_j}$ 

$$T(y) = \sum_{i=0}^{n-1} \frac{1}{v_i} \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2}$$
$$(T_{,y_j})_j(y) = \left( \frac{y_j - y_{j-1}}{v_{j-1} \sqrt{(x_j - x_{j-1})^2 + (y_j - y_{j-1})^2}} - \frac{y_{j+1} - y_j}{v_j \sqrt{(x_{j+1} - x_j)^2 + (y_{j+1} - y_j)^2}} \right)_j$$

# 4. Multivariate Differentiation

## Ableitungsterme zweiter Ordnung

Baywatch: Optimierungsproblem



**Satz**

Sei  $D \subseteq \mathbb{R}^n$  und  $f \in C^2(D)$ , dann gilt

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad \forall 1 \leq i, j \leq n.$$

(ohne Beweis)

**Satz**

Sei  $D \subseteq \mathbb{R}^n$  und  $f \in C^2(D)$ , dann gilt

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i} \quad \forall 1 \leq i, j \leq n.$$

(ohne Beweis)

**Definition: Laplace-Operator**

Zu einer skalaren Funktion  $u : \mathbb{R}^n \rightarrow \mathbb{R}$  heißt die Abbildung

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

*Laplace von u.* Der Operator  $\Delta$  heißt *Laplace Operator*.

Memo:

$$\Delta u = u_{x_1} x_1 + \dots + u_{x_n} x_n = \sum_{i=1}^n u_{x_i} x_i$$

Memo:

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Beispiel:

$$\Delta x_1^2 + \cos x_2 = (x_1^2 + \cos x_2)_{x_1 x_1} + (x_1^2 + \cos x_2)_{x_2 x_2} = (2 x_1)_{x_1} - (\sin x_2)_{x_2} = 2 - \cos x_2$$

Memo:

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Beispiel:

$$\Delta(x_1^2 + \cos x_2) = (x_1^2 + \cos x_2)_{x_1 x_1} + (x_1^2 + \cos x_2)_{x_2 x_2} = (2x_1)_{x_1} - (\sin x_2)_{x_2} = 2 - \cos x_2$$



Der Laplace von  $u$  ist gleich der Spur der Hesse-Matrix.

Memo:

$$\Delta u = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \sum_{i=1}^n u_{x_i x_i}$$

Beispiel:

$$\Delta(x_1^2 + \cos x_2) = (x_1^2 + \cos x_2)_{x_1 x_1} + (x_1^2 + \cos x_2)_{x_2 x_2} = (2x_1)_{x_1} - (\sin x_2)_{x_2} = 2 - \cos x_2$$



Der Laplace von  $u$  ist gleich der Spur der Hesse-Matrix.

Beispiel:

$$\Delta u = \text{Spur } Hu = \text{Spur} \begin{pmatrix} 2 & 0 \\ 0 & -\cos x_2 \end{pmatrix} = 2 - \cos x_2$$

Die Hesse-Matrix von  $u$  ist auch die Jacobi-Matrix von  $\nabla u$ . Daher ist der Laplace-Operator von  $u$  auch die Divergenz des Gradienten von  $u$ :

$$\Delta u = \nabla \cdot \nabla u$$

Die Hesse-Matrix von  $u$  ist auch die Jacobi-Matrix von  $\nabla u$ . Daher ist der Laplace-Operator von  $u$  auch die Divergenz des Gradienten von  $u$ :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u$$

Die Hesse-Matrix von  $u$  ist auch die Jacobi-Matrix von  $\nabla u$ . Daher ist der Laplace-Operator von  $u$  auch die Divergenz des Gradienten von  $u$ :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix}$$

Die Hesse-Matrix von  $u$  ist auch die Jacobi-Matrix von  $\nabla u$ . Daher ist der Laplace-Operator von  $u$  auch die Divergenz des Gradienten von  $u$ :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix} = \frac{\partial}{\partial x_1} u_{x_1} + \cdots + \frac{\partial}{\partial x_n} u_{x_n}$$

Die Hesse-Matrix von  $u$  ist auch die Jacobi-Matrix von  $\nabla u$ . Daher ist der Laplace-Operator von  $u$  auch die Divergenz des Gradienten von  $u$ :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix} = \frac{\partial}{\partial x_1} u_{x_1} + \cdots + \frac{\partial}{\partial x_n} u_{x_n} = u_{x_1 x_1} + \cdots + u_{x_n x_n}$$

Die Hesse-Matrix von  $u$  ist auch die Jacobi-Matrix von  $\nabla u$ . Daher ist der Laplace-Operator von  $u$  auch die Divergenz des Gradienten von  $u$ :

$$\Delta u = \nabla \cdot \nabla u$$

konkret:

$$\nabla \cdot \nabla u = \nabla \cdot \begin{pmatrix} u_{x_1} \\ \vdots \\ u_{x_n} \end{pmatrix} = \frac{\partial}{\partial x_1} u_{x_1} + \cdots + \frac{\partial}{\partial x_n} u_{x_n} = u_{x_1 x_1} + \cdots + u_{x_n x_n} = \Delta u$$

### Übersicht

Abbildung	1. Ableitung	2. Ableitung
$f : \mathbb{R}^n \rightarrow \mathbb{R}$ $\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \mapsto f(x_1, \dots, x_n)$	$\text{Gradient} \quad \nabla f = \begin{pmatrix} f_{x_1} \\ \vdots \\ f_{x_n} \end{pmatrix}$	$\text{Hessematrix} \quad Hf = \text{grad } \nabla f = \begin{pmatrix} f_{x_1 x_1} & \cdots & f_{x_1 x_n} \\ \vdots & \ddots & \vdots \\ f_{x_n x_1} & \cdots & f_{x_n x_n} \end{pmatrix}$
		$\text{Laplace} \quad \Delta f = \sum_{i=1}^n f_{x_i x_i}$

Bemerkung: Der Gradient zeigt in Richtung des steilsten Anstiegs

Der Laplace ist die Divergenz des Gradienten:  $\Delta f = \nabla \cdot \nabla f$

und die Spur der Hessematrix:  $\Delta f = \text{Spur } Hf$

Richtungsableitungen		
$v, w \in \mathbb{R}^n, \ w\  = \ v\  = 1$	$f_v = \nabla f \cdot v$	$f_{vw} = v^T Hf w$
$u, g : \mathbb{R}^n \rightarrow \mathbb{R}^n$ $\ u(x)\  = \ g(x)\  = 1 \quad \forall x \in \mathbb{R}^n$	$f_{u(x)g(x)} = \nabla f(x) \cdot u(x)$	$\begin{aligned} f_{u(x)g(x)} &= \\ u(x)^T Hf(x) g(x) &+ \nabla f(x)^T Du g(x) \end{aligned}$
$g : \mathbb{R} \rightarrow \mathbb{R}^m$ $t \mapsto \begin{pmatrix} g_1(t) \\ \vdots \\ g_m(t) \end{pmatrix}$	$g'(t) = \begin{pmatrix} g'_1(t) \\ \vdots \\ g'_m(t) \end{pmatrix}$	$g''(t) = \begin{pmatrix} g''_1(t) \\ \vdots \\ g''_m(t) \end{pmatrix}$

Bemerkung: Alle Ableitungen werden kptw durchgeführt

Jacobi-Matrix $Df =$		
$\begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \mapsto \begin{pmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{pmatrix}$		$\begin{pmatrix} f_{1,x_1} & \cdots & f_{1,x_n} \\ \vdots & \ddots & \vdots \\ f_{m,x_1} & \cdots & f_{m,x_n} \end{pmatrix}$

Bemerkung: Die Jacobi-Matrix des Gradienten ist die Hessematrix:  $D\nabla f = Hf$

Divergenz		
$f : \mathbb{R}^n \rightarrow \mathbb{R}^m$	$\nabla \cdot f = \sum_{i=1}^n f_{i,x_i}$	

Bemerkung: Die Divergenz ist die Spur der Jacobi-Matrix

Kettenregel:	$f : \mathbb{R}^n \rightarrow \mathbb{R}, g : \mathbb{R} \rightarrow \mathbb{R}^n$
	$\frac{d}{dt}(f \circ g)(t) = \sum_{i=1}^n f_{g_i}(g'_i(t)) = \nabla f(g) \cdot g'(t)$

#### Lernziele



- Sie können zweite partielle Ableitungen einer multivariaten Funktion berechnen.
- Sie können die Hesse-Matrix und den Lapalce einer multivariaten Funktion berechnen.
- Sie können kritische Punkte von multivariaten Funktionen berechnen und Sie wissen wie Sie auch Maxima und Minima prüfen.
- Sie können Querverbindungen zwischen Hesse-Matrix, Divergenz, Gradient, etc. aufzeigen und erklären.


## 4. Multivariate Differentiation

von diskreten, multivariaten Funktionen

digitale Bilder als diskrete Funktionen



Pixelmatrix eines Bildes ...



... als Graph einer diskreten Funktion

## digitale Bilder als diskrete Funktionen

## Definition: digitale Bilder als diskrete Funktionen

Auf den Indexmengen  $I_N = [1, N] \cap \mathbb{N}$  und  $I_M = [1, M] \cap \mathbb{N}$  werden folgende Abbildungen definiert:  
8-bit, RGB:

$$\begin{aligned} P : I_M \times I_N &\subset \mathbb{N}^2 \rightarrow [0, 255]^3 \\ (i, j) &\mapsto (P_{ij}^R, P_{ij}^G, P_{ij}^B) \end{aligned}$$

skaliert, grauwertig:

$$\begin{aligned} P : I_M \times I_N &\subset \mathbb{N}^2 \rightarrow [0, 1] \\ (i, j) &\mapsto P_{ij} \end{aligned}$$

## Ableitung erster Ordnung

Definition: Differenzenquotient für partielle Ableitungen

in  $x$ - und  $y$ -Richtung:

$$u_x^+ \approx \frac{u(x+h, y) - u(x, y)}{h} \quad \text{Vorwärtsdifferenzenquotient}$$

$$u_x^- \approx \frac{u(x, y) - u(x-h, y)}{h} \quad \text{Rückwärtsdifferenzenquotient}$$

$$u_x^\pm \approx \frac{1}{2} (u_x^+ + u_x^-) \quad \text{gemittelter Differenzenquotient}$$


$$u_y^+ \approx \frac{u(x, y+h) - u(x, y)}{h} \quad \text{Vorwärtsdifferenzenquotient}$$

$$u_y^- \approx \frac{u(x, y) - u(x, y-h)}{h} \quad \text{Rückwärtsdifferenzenquotient}$$

$$u_y^\pm \approx \frac{1}{2} (u_y^+ + u_y^-) \quad \text{gemittelter Differenzenquotient}$$

## Ableitung erster Ordnung

$$\mathcal{P}_{ij} = \begin{pmatrix} P_{i-1,j-1} & P_{i-1,j} & P_{i-1,j+1} \\ P_{i,j-1} & P_{i,j} & P_{i,j+1} \\ P_{i+1,j-1} & P_{i+1,j} & P_{i+1,j+1} \end{pmatrix}$$



## Ableitung erster Ordnung

$$\mathcal{P}_{ij} = \begin{pmatrix} P_{i-1,j-1} & P_{i-1,j} & P_{i-1,j+1} \\ P_{i,j-1} & P_{i,j} & P_{i,j+1} \\ P_{i+1,j-1} & P_{i+1,j} & P_{i+1,j+1} \end{pmatrix}$$

$$= \begin{pmatrix} u(x-1, y-1) & u(x, y-1) & u(x+1, y-1) \\ u(x-1, y) & u(x, y) & u(x+1, y) \\ u(x-1, y+1) & u(x, y+1) & u(x+1, y+1) \end{pmatrix}$$

$$h = 1$$

A =   
 *P<sub>33</sub>*

0	0	0	128	100	20	20
0	128	100	20	20	100	100
128	200	100	200	200	100	200
128	254	254	254	254	200	200
0	10	254	200	100	100	200
10	254	254	254	254	200	200
10	254	254	254	254	200	200

## Definition: partielle Ableitungen eines digitalen Bildes

$$P_{ij,x}^+ \approx P_{i,j+1} - P_{i,j}$$

Vorwärtsdifferenzenquotient

$$P_{ij,x}^- \approx P_{i,j} - P_{i,j-1}$$

Rückwärtsdifferenzenquotient

$$P_x^\pm \approx \frac{1}{2} (P_{i,j+1} - P_{i,j-1})$$

gemittelter Differenzenquotient

$$P_{ij,y}^+ \approx P_{i+1,j} - P_{i,j}$$

Vorwärtsdifferenzenquotient

$$P_{ij,y}^- \approx P_{i,j} - P_{i-1,j}$$

Rückwärtsdifferenzenquotient

$$P_y^\pm \approx \frac{1}{2} (P_{i+1,j} - P_{i-1,j})$$

gemittelter Differenzenquotient

$$\Rightarrow \nabla_h P_{ij} = \frac{1}{2} \begin{pmatrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{pmatrix} \quad \text{Gradient über gemittelte Diff.-quot.}$$

Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \left( \begin{array}{c|c|c} 1 & 6 & 0 \\ \hline 1 & 3 & 2 \\ \hline 0 & 1 & 9 \end{array} \right)$$

Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \left( \begin{array}{c|cc|c} 1 & 6 & 0 \\ \hline 1 & 3 & 2 \\ \hline 0 & 1 & 9 \end{array} \right)$$

erhalten wir den diskreten Gradienten

$$\begin{aligned}\nabla_h P_{ij} &= \frac{1}{2} \left( \begin{matrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{matrix} \right) \\ &= \frac{1}{2} \begin{pmatrix} 2 - 1 \\ 1 - 6 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix}\end{aligned}$$

Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 6 & 0 \\ 1 & 3 & 2 \\ 0 & 1 & 9 \end{pmatrix}$$

erhalten wir den diskreten Gradienten

$$\begin{aligned}\nabla_h P_{ij} &= \frac{1}{2} \left( \begin{matrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{matrix} \right) \\ &= \frac{1}{2} \begin{pmatrix} 2 - 1 \\ 1 - 6 \end{pmatrix} = \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix}\end{aligned}$$



Beispiel: Gradient und Richtungsableitung



Für das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 6 & 0 \\ 1 & 3 & 2 \\ 0 & 1 & 9 \end{pmatrix}$$

erhalten wir den diskreten Gradienten

$$\begin{aligned}\nabla_h P_{ij} &= \frac{1}{2} \left( \begin{matrix} P_{i,j+1} - P_{i,j-1} \\ P_{i+1,j} - P_{i-1,j} \end{matrix} \right) \\ &= \frac{1}{2} \left( \begin{matrix} 2 - 1 \\ 1 - 6 \end{matrix} \right) = \frac{1}{2} \left( \begin{matrix} 1 \\ -5 \end{matrix} \right)\end{aligned}$$

Kennlinie

$$C(\|\nabla P\|) = \frac{\beta}{\sqrt{\beta^2 + \|\nabla P\|^2}}$$

<https://www.geogebra.org/m/dsvjj4b4>



## 4. Multivariate Differentiation

von diskreten, multivariaten Funktionen


Beispiel: Gradient und Richtungsableitung



$$\square \quad \beta = 0.1 \quad \leftrightarrow \quad \square$$

$$\square \quad \beta = 0.3 \quad \leftrightarrow \quad \square$$

$$C(\|\nabla P\|) = \frac{\beta}{\sqrt{\beta^2 + \|\nabla P\|^2}}$$



## 4. Multivariate Differentiation

von diskreten, multivariaten Funktionen


Beispiel: Gradient und Richtungsableitung



$$\square \leftrightarrow \beta = 0.1 \quad \times \times$$

$$\times \times \leftrightarrow \beta = 0.3 \quad \square$$

$$C(\|\nabla P\|) = \frac{\beta}{\sqrt{\beta^2 + \|\nabla P\|^2}}$$



Beispiel: Gradient und Richtungsableitung



Patch:

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 6 & 0 \\ 1 & 3 & 2 \\ 0 & 1 & 9 \end{pmatrix}$$

Gradient:

$$\nabla_h P_{ij} = \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix}, \quad \|\nabla_h P_{ij}\| \approx 2.55$$

Richtungsableitung:

$$P_{ij,v} \text{ in Richtung } v = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\begin{aligned} P_{ij,v} &= \nabla_h P_{ij} \cdot v \frac{1}{\|v\|} \\ &= \frac{1}{2} \begin{pmatrix} 1 \\ -5 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 1 \end{pmatrix} \frac{1}{\sqrt{2}} \\ &= -\sqrt{2} \approx -1.41 \end{aligned}$$



partielle Ableitungen zweiter Ordnung

Definition: Laplace-Operator für diskrete Funktionen

$$\begin{aligned} u_{h,xx} &= \frac{u(x+h, y) - 2u(x, y) + u(x-h, y)}{h^2} \\ u_{h,yy} &= \frac{u(x, y+h) - 2u(x, y) + u(x, y-h)}{h^2} \\ \Rightarrow \Delta_h u &= \frac{u(x+h, y) - u(x-h, y) + u(x, y+h) - u(x, y-h) - 4u(x, y)}{h^2} \end{aligned}$$

partielle Ableitungen zweiter Ordnung

Definition: Laplace-Operator für diskrete Funktionen

$$u_{h,xx} = \frac{u(x+h, y) - 2u(x, y) + u(x-h, y)}{h^2}$$
$$u_{h,yy} = \frac{u(x, y+h) - 2u(x, y) + u(x, y-h)}{h^2}$$
$$\Rightarrow \Delta_h u = \frac{u(x+h, y) - u(x-h, y) + u(x, y+h) - u(x, y-h) - 4u(x, y)}{h^2}$$

Definition: Laplace-Operator für digitale Bilder

$$P_{ij,xx} = P_{i,j+1} - 2P_{ij} + P_{i,y-1}$$
$$P_{ij,yy} = P_{i+1,j} - 2P_{ij} + P_{i-1,y}$$
$$\Rightarrow \Delta_h P_{ij} = P_{i+1,j} + P_{i-1,y} + P_{i,j+1} + P_{i,y-1} - 4P_{ij}$$

0	1	0
1	-4	1
0	1	0

## Beispiel

Für das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} P_{i-1,j-1} & P_{i-1,j} & P_{i-1,j+1} \\ \hline P_{i,j-1} & P_{i,j} & P_{i,j+1} \\ \hline P_{i+1,j-1} & P_{i+1,j} & P_{i+1,j+1} \end{pmatrix} = \begin{pmatrix} 1 & 2 & 3 \\ \hline 4 & 6 & 2 \\ \hline 2 & 5 & 9 \end{pmatrix}$$

erhalten wir die diskreten zweiten Ableitungen

$$P_{ij,xx} = 2 - 2 \cdot 6 + 4 = -6$$

$$P_{ij,yy} = 5 - 2 \cdot 6 + 2 = -5$$

und damit den Laplace

$$\Delta_h P_{ij} = -6 - 5 = -11$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

## Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

multiplizieren wir mit dem Filter  $\mathcal{F}_\Delta$

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

## Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

multiplizieren wir mit dem Filter  $\mathcal{F}_\Delta$ 

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

und summieren auf:

multiplizieren wir mit dem Filter  $\mathcal{F}_\Delta$ 

$$\Delta_h \mathcal{P}_{ij} = \sum_{l,k} (\mathcal{P}_{ij} : \mathcal{F}_\Delta)_{lk}$$

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

multiplizieren wir mit dem Filter  $\mathcal{F}_\Delta$ 

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

und summieren auf:

$$\Delta_h \mathcal{P}_{ij} = \sum_{l,k} (\mathcal{P}_{ij} : \mathcal{F}_\Delta)_{lk}$$

$$= \sum_{l,k} \left( \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix} \right)_{lk}$$

## Filterschreibweise

Definition: Hadamar-Multiplikation

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix} : \begin{pmatrix} \alpha & \beta \\ \gamma & \delta \end{pmatrix} = \begin{pmatrix} \alpha a & \beta b \\ \gamma c & \delta d \end{pmatrix}$$

Beispiel: Das Patch

$$\mathcal{P}_{ij} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix}$$

multiplizieren wir mit dem Filter  $\mathcal{F}_\Delta$ 

$$\mathcal{P}_{ij} : \mathcal{F}_\Delta = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 6 & 2 \\ 2 & 5 & 9 \end{pmatrix} : \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

$$= \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}$$

und summieren auf:

$$\Delta_h \mathcal{P}_{ij} = \sum_{l,k} (\mathcal{P}_{ij} : \mathcal{F}_\Delta)_{lk}$$

$$= \sum_{l,k} \begin{pmatrix} 0 & 2 & 0 \\ 4 & -24 & 2 \\ 0 & 5 & 0 \end{pmatrix}_{lk}$$

$$= 2 + 4 - 24 + 2 + 5 = -11$$

## Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in  $x$ -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{lj} : \left( \begin{array}{c|c|c} \square & \square & \square \\ \hline \square & \square & \square \\ \hline \square & \square & \square \end{array} \right) ?$$

## Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in  $x$ -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{lj} : \left( \begin{array}{c|c|c} 0 & 0 & 0 \\ \hline -0.5 & 0 & 0.5 \\ \hline 0 & 0 & 0 \end{array} \right)$$

## Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in  $x$ -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{lj} : \left( \begin{array}{c|c|c} 0 & 0 & 0 \\ \hline -0.5 & 0 & 0.5 \\ \hline 0 & 0 & 0 \end{array} \right)$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in  $y$ -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i+1,j} - P_{i-1,j}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_y = \sum_{l,k} \mathcal{P}_{lj} : \left( \begin{array}{c|c|c} \square & \square & \square \\ \hline \square & \square & \square \\ \hline \square & \square & \square \end{array} \right) ?$$

## Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in  $x$ -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in  $y$ -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i+1,j} - P_{i-1,j}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_y = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & -0.5 & 0 \\ 0 & 0 & 0 \\ 0 & 0.5 & 0 \end{pmatrix}$$

## Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in  $x$ -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{ij} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{ij} : \left( \begin{array}{c|c|c} 0 & 0 & 0 \\ \hline -0.5 & 0 & 0.5 \\ \hline 0 & 0 & 0 \end{array} \right)$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in  $y$ -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i+1,j} - P_{i-1,j}) = \sum_{l,k} \mathcal{P}_{ij} : \mathcal{F}_y = \sum_{l,k} \mathcal{P}_{ij} : \left( \begin{array}{c|c|c} 0 & -0.5 & 0 \\ \hline 0 & 0 & 0 \\ \hline 0 & 0.5 & 0 \end{array} \right)$$

Wie lautet der Filter zur ersten Ableitung (Vorwärtsdiff-quot) in  $x$ -Richtung:

$$P_{ij,x}^+ = \sum_{l,k} \mathcal{P}_{ij} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{ij} : \left( \begin{array}{c|c|c} \square & \square & \square \\ \hline \square & \square & \square \\ \hline \square & \square & \square \end{array} \right) ?$$

## Saalaufgabe



Wie lautet der Filter zur ersten, gemittelten Ableitung in  $x$ -Richtung:

$$P_{ij,x} = \frac{1}{2} (P_{i,j+1} - P_{i,j-1}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & 0 & 0 \\ -0.5 & 0 & 0.5 \\ 0 & 0 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten, gemittelten Ableitung in  $y$ -Richtung:

$$P_{ij,y} = \frac{1}{2} (P_{i+1,j} - P_{i-1,j}) = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_y = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & -0.5 & 0 \\ 0 & 0 & 0 \\ 0 & 0.5 & 0 \end{pmatrix}$$

Wie lautet der Filter zur ersten Ableitung (Vorwärtsdiff-quot) in  $x$ -Richtung:

$$P_{ij,x}^+ = \sum_{l,k} \mathcal{P}_{lj} : \mathcal{F}_x = \sum_{l,k} \mathcal{P}_{lj} : \begin{pmatrix} 0 & 0 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & 0 \end{pmatrix}$$

## Ausblick

Diffusionsgleichung (isotrop):

$$P_t - \Delta P = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta \Delta P^{alt}$$

```
for l=1:LOOPmax
    P = P + delta*P:FΔ
end
```



## Ausblick

Diffusionsgleichung (isotrop):

$$P_t - \Delta P = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta \Delta P^{alt}$$

```
for l=1:LOOPmax
    P = P + delta*P:FΔ
end
```



## Ausblick

Diffusionsgleichung (anisotrop):

$$P_t - P_{vv} = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta P_{vv}^{alt}$$

$$P_{vv} = \frac{v_1^2}{\|v\|^2} P_{xx} + \frac{2 v_1 v_2}{\|v\|^2} P_{xy} + \frac{v_2^2}{\|v\|^2} P_{yy}$$

$$P_{xx} = \mathcal{P} : \mathcal{F}_{xx}, \dots$$

```
for l=1:LOOPmax
    P = P + delta*P_{vv}
end
```

$$v = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \frac{1}{\sqrt{2}}$$



## Ausblick

Diffusionsgleichung (anisotrop):

$$P_t - P_{vv} = 0 \quad \Rightarrow \quad P^{neu} = P^{alt} + \delta P_{vv}^{alt}$$

$$P_{vv} = \frac{v_1^2}{\|v\|^2} P_{xx} + \frac{2 v_1 v_2}{\|v\|^2} P_{xy} + \frac{v_2^2}{\|v\|^2} P_{yy}$$

$$P_{xx} = \mathcal{P} : \mathcal{F}_{xx}, \dots$$

```
for l=1:LOOPmax
    P = P + delta*P_{vv}
end
```

$$v = \begin{pmatrix} 1 \\ -1 \end{pmatrix} \frac{1}{\sqrt{2}}$$



## Ausblick

Diffusionsgleichung (anisotrop/bildabhängig):

$$P^{neu} = P^{alt} + \delta P_{\nabla P \nabla P}^{alt}$$

$P_{\nabla P \nabla P}$  lässt sich nicht mehr als Linearkombination von Filtern reiner partieller Ableitungen darstellen.

```
for l=1:LOOPmax
    P = P + delta*P_{\nabla P \nabla P}
end
```



## Ausblick

Diffusionsgleichung (anisotrop/bildabhängig):


$$P^{neu} = P^{alt} + \delta P_{\nabla P^\perp \nabla P^\perp}^{alt}$$

$P_{\nabla P^\perp \nabla P^\perp}$  lässt sich nicht mehr als Linearkombination von Filtern reiner partieller Ableitungen darstellen.

```
for l=1:LOOPmax
    P = P + delta*P_{\nabla P^\perp \nabla P^\perp}
end
```



### Ausblick



BiLeSA-App auf Google Play

### Lernziele



- Sie können den Gradienten und eine beliebige Richtungsableitung einer diskreten, multivariaten Funktion berechnen.
- Sie können die Hessematrix und den Laplace-Operator einer diskreten, multivariaten Funktion berechnen.
- Sie können die Ableitungsterme in Filterschreibweise darstellen.
- Sie sind in der Lage einen Filter für die dritten Ableitungen aufzustellen. Es ist Ihnen klar, dass man sich nicht an das 3x3-Format halten muss.
- Die Grundidee wie man Optimierungsprobleme mit mehreren Freiheitsgraden (Unbekannte) löst ist Ihnen klar. Dabei ist selbstverständlich die Nullstellensuche ein separates Problem (Numerik).